UNIVERSIDAD TECNOLÓGICA
DE TULA-TEPEJI

Exploración y diagnóstico del conjunto de datos

Mantenimiento predictivo de maquinaria industrial

AI4I 2020 Predictive Maintenance Dataset

Alumno	Diego Salinas Laguna
Asignatura	Extracción de Conocimiento en Bases de Datos
Modalidad	Recursamiento 2026
Unidad y actividad	Unidad II · Actividad de Evaluación 1
Fecha de elaboración	9 de noviembre de 2026

10,000 observaciones · 14 columnas · 6 predictores principales

Diagnóstico previo a limpieza y transformación. El archivo original se conserva sin modificaciones.

UNIDAD II / ACTIVIDAD DE EVALUACIÓN 1

1. Dataset y propósito

El proyecto busca conocer qué condiciones de operación se relacionan con fallas de maquinaria. Esta actividad examina el conjunto de datos antes de modificarlo, para detectar problemas de calidad y preparar propuestas de regresión, clasificación y agrupamiento.

Aspecto	Descripción
Archivo	data/raw/ai4i2020.csv
Fuente	UCI Machine Learning Repository; AI4I 2020; DOI 10.24432/C5HS5C
Formato	CSV tabular: 10,000 filas y 14 columnas
Contenido	Temperaturas, velocidad de giro, torque, desgaste, variante de producto y estados de falla
Procedencia	Datos sintéticos generados para representar condiciones industriales; no son lecturas directas de sensores reales
Estructura	Estructurada: columnas definidas y una observación por fila
Licencia	Creative Commons Attribution 4.0

Las seis variables predictoras principales son Type y cinco mediciones. Las otras ocho columnas son dos identificadores y seis etiquetas. Una fila no equivale necesariamente a una máquina distinta.

No hay fecha, frecuencia de muestreo ni identificador de máquina. No se puede calcular tiempo hasta una falla ni validar secuencias reales de mantenimiento con este archivo.

UNIDAD II / ACTIVIDAD DE EVALUACIÓN 1

2. Carga y exploración con Pandas

Instrucción	Resultado e interpretación
pd.read_csv(archivo)	Carga el CSV original en df. Se usa una ruta relativa a la raíz del proyecto.
df.head()	Permite ver cinco ejemplos de mediciones y etiquetas. Una muestra no describe toda la distribución.
df.shape	(10000, 14): diez mil observaciones y catorce columnas.
df.columns	Permite revisar los nombres exactos y unidades; espacios y corchetes se conservan.
df.info()	Las catorce columnas tienen 10,000 valores no nulos. Dos son texto y doce son numéricas.
df.dtypes	Identificadores y etiquetas pueden ser enteros sin ser mediciones continuas. El texto aparece como str u object según la versión.
df.describe()	Resume conteo, media, desviación, mínimos, cuartiles y máximos. Machine failure tiene media 0.0339, equivalente a 3.39% de fallas.

El notebook incluye cada instrucción, su salida ejecutada y una interpretación. La media de UDI no tiene significado físico: ese campo se utiliza para localizar filas, no para explicar fallas.

Las temperaturas están expresadas en kelvin. Por ejemplo, 300 K equivale aproximadamente a 26.85 °C; no debe interpretarse como 300 °C.

UNIDAD II / ACTIVIDAD DE EVALUACIÓN 1

3. Diccionario: predictores e identificadores

Se conserva el nombre exacto de las columnas. Type tiene un orden conceptual de calidad (L, M, H), pero no implica distancias numéricas iguales entre categorías.

Variable	Descripción	Tipo y clasificación	Unidad / utilidad
UDI	Identificador de fila	int64; Cualitativa; Nominal (identificador)	Sin unidad. Localizar registros; excluir de modelos
Product ID	Código del producto y variante	str/object; Cualitativa; Nominal (identificador)	Sin unidad. Trazabilidad; excluir de modelos
Type	Variante de calidad L, M o H	str/object; Cualitativa; Ordinal conceptual	L/M/H. Comparar variantes; codificar sin imponer distancias
Air temperature [K]	Temperatura del ambiente	float64; Cuantitativa; Continua	K. Explicar condiciones de operación
Process temperature [K]	Temperatura durante el proceso	float64; Cuantitativa; Continua	K. Explicar condiciones de operación
Rotational speed [rpm]	Velocidad de rotación	int64; Cuantitativa; Discreta	rpm. Explicar condiciones de operación
Torque [Nm]	Fuerza de giro	float64; Cuantitativa; Continua	Nm. Explicar condiciones de operación
Tool wear [min]	Tiempo acumulado de uso de la herramienta	int64; Cuantitativa; Discreta	min. Explicar condiciones de operación

UNIDAD II / ACTIVIDAD DE EVALUACIÓN 1

4. Diccionario: etiquetas de falla

Variable	Descripción	Tipo / clase	Unidad y utilidad
Machine failure	Estado general de falla	int64 / cualitativa binaria	0=no; 1=sí. Objetivo de clasificación
TWF	Falla por desgaste de herramienta	int64 / cualitativa binaria	0=no; 1=sí. Diagnóstico; excluir como entrada al predecir falla
HDF	Falla por disipación de calor	int64 / cualitativa binaria	0=no; 1=sí. Diagnóstico; excluir como entrada al predecir falla
PWF	Falla por potencia	int64 / cualitativa binaria	0=no; 1=sí. Diagnóstico; excluir como entrada al predecir falla
OSF	Falla por sobreesfuerzo	int64 / cualitativa binaria	0=no; 1=sí. Diagnóstico; excluir como entrada al predecir falla
RNF	Falla aleatoria	int64 / cualitativa binaria	0=no; 1=sí. Diagnóstico; excluir como entrada al predecir falla

Machine failure es el objetivo de clasificación: 0 significa sin falla y 1 con falla. Los otros cinco campos describen modos específicos. Pueden coexistir varios modos en una fila.

Aunque los valores sean números, las etiquetas son categorías binarias. TWF, HDF, PWF, OSF y RNF no deben utilizarse como entradas para anticipar Machine failure: revelarían resultados que el modelo debería predecir. UDI y Product ID también se excluyen como predictores.

UNIDAD II / ACTIVIDAD DE EVALUACIÓN 1

5. Diagnóstico de calidad

Revisión	Resultado	Tratamiento posterior
Faltantes	0 en las 14 columnas (0%)	No imputar; revisar la causa si aparecen en datos nuevos.
Filas completas duplicadas	0	No eliminar. Verificar origen si aparecen repeticiones futuras.
UDI y Product ID repetidos	0 en cada identificador	Conservar para trazabilidad.
Contenido repetido sin IDs	0	Revisar coincidencias antes de asumir duplicación de carga.
Dominios y tipos	Sin negativos inválidos, categorías ajenas, valores no finitos ni etiquetas fuera de 0/1	Mantener controles al incorporar datos.
Coherencia de etiquetas	27 discrepancias frente a la unión de modos	Revisar con la fuente; no corregir automáticamente.
Desbalance	339 con falla; 9,661 sin falla	Evaluar detección de fallas y falsas alarmas.

Se revisaron UDI en 1..10000, Type en L/M/H, prefijo de Product ID, temperaturas positivas, velocidad y torque positivos, desgaste no negativo y temperatura del proceso mayor o igual que la del aire. Estas comprobaciones no sustituyen límites de un fabricante real.

UCI describe que cualquier modo activo produce una falla general. El CSV tiene 27 diferencias con esa regla. Además, la descripción refiere cinco fallas aleatorias, pero el archivo contiene 19 RNF. Se reportan estas diferencias y se conservan los valores originales.

UNIDAD II / ACTIVIDAD DE EVALUACIÓN 1

6. Estadística de las mediciones

Variable	Media	Mediana	Mín.	Máx.	Desv. estándar
Air temperature [K]	300.005	300.100	295.300	304.500	2.000
Process temperature [K]	310.006	310.100	305.700	313.800	1.484
Rotational speed [rpm]	1538.776	1503.000	1168.000	2886.000	179.284
Torque [Nm]	39.987	40.100	3.800	76.600	9.969
Tool wear [min]	107.951	108.000	0.000	253.000	63.654

La temperatura del aire se concentra cerca de 300 K y la del proceso cerca de 310 K. El torque promedio es 39.987 Nm, con desviación estándar de 9.969 Nm: el esfuerzo de giro varía entre observaciones.

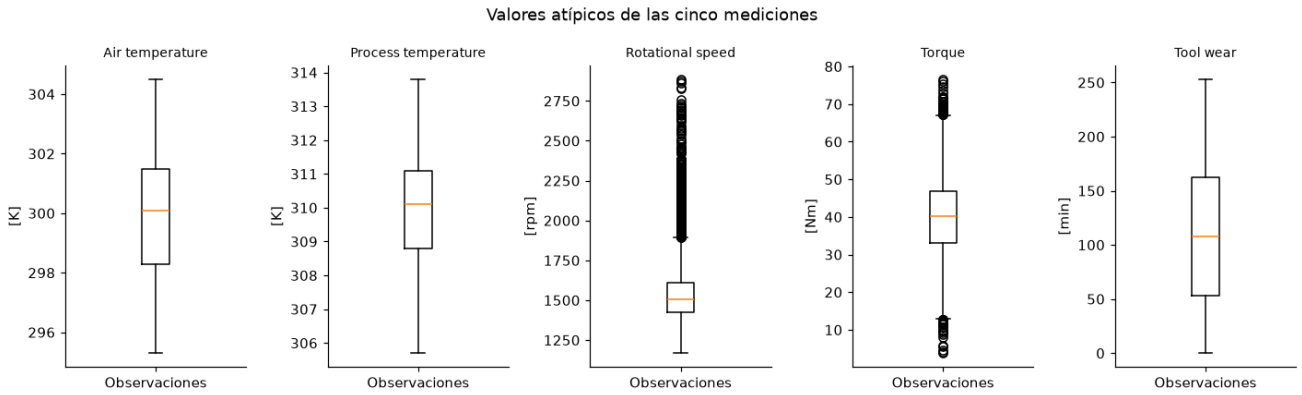
La velocidad media, 1538.776 rpm, es mayor que la mediana, 1503 rpm. Esto es compatible con una distribución que se extiende hacia velocidades altas. El desgaste abarca de 0 a 253 minutos; un cero puede corresponder a una herramienta nueva.

Las medidas describen este archivo sintético. No prueban que una temperatura, torque o desgaste particular cause una falla ni establecen un umbral de mantenimiento.

UNIDAD II / ACTIVIDAD DE EVALUACIÓN 1

7. Detección inicial de atípicos

Variable	Límite inferior	Límite superior	Casos IQR
Air temperature [K]	293.5	306.3	0
Process temperature [K]	305.35	314.55	0
Rotational speed [rpm]	1139.5	1895.5	418
Torque [Nm]	12.8	67.2	69
Tool wear [min]	-110.5	325.5	0

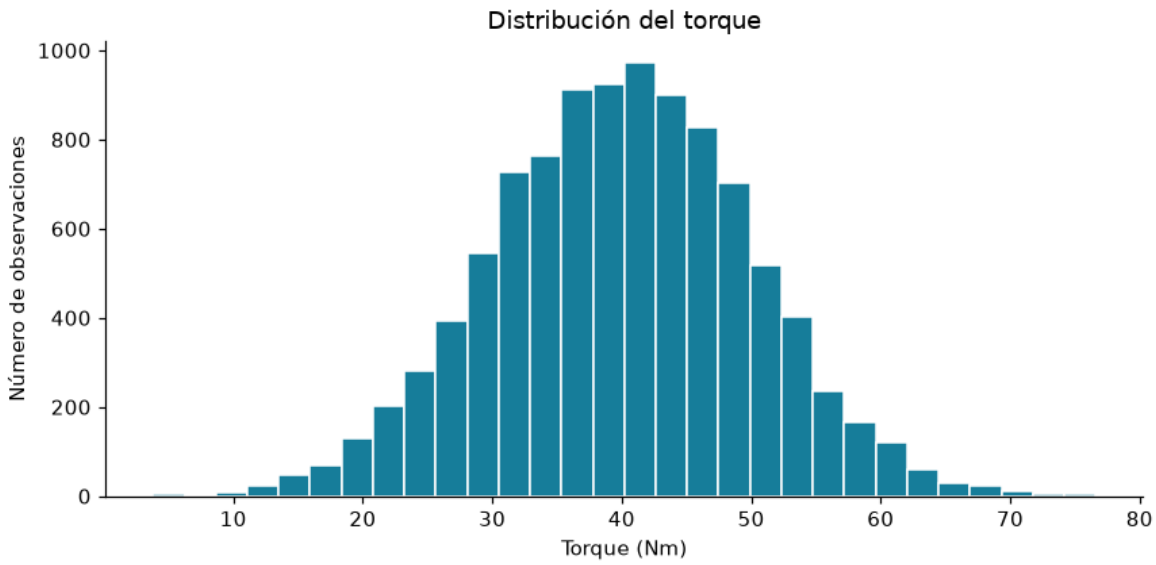


Se usa la regla de 1.5 veces el rango intercuartílico (IQR). Las temperaturas y el desgaste no presentan alertas con este criterio. La velocidad y el torque sí presentan extremos.

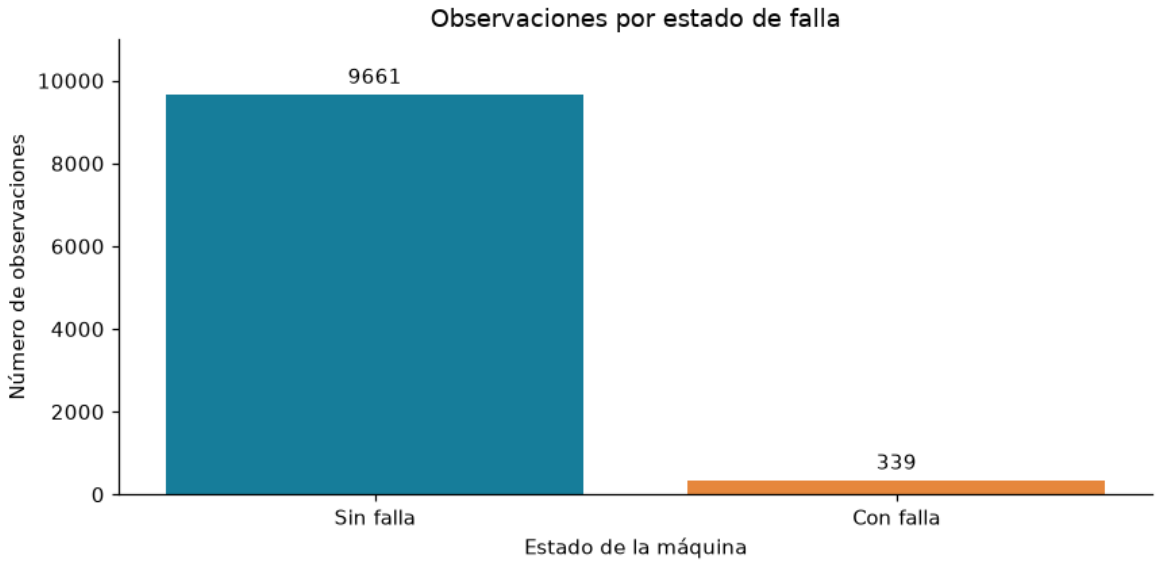
Para velocidad, las observaciones extremas pueden representar operación rápida; para torque, esfuerzos poco frecuentes. En ambos casos se conservarán y revisarán, porque pueden aportar información sobre fallas. No se eliminan ni recortan valores. Los límites IQR son estadísticos, no límites físicos de seguridad.

UNIDAD II / ACTIVIDAD DE EVALUACIÓN 1

8. Distribución y balance de fallas



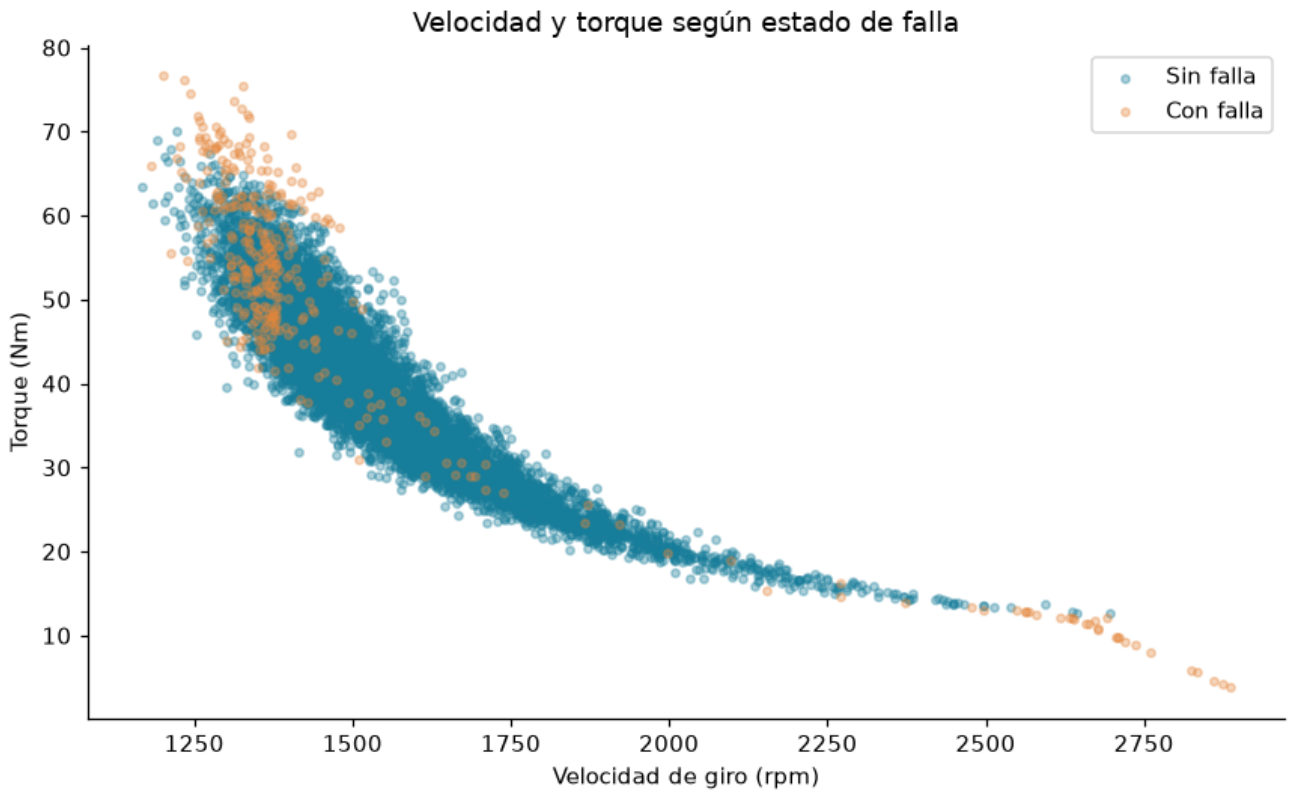
La mayor parte del torque se agrupa cerca de 40 Nm. Las colas contienen valores menos frecuentes; no se clasifican como errores solo por aparecer poco.



Las fallas representan 3.39%. Predecir siempre “sin falla” daría 96.61% de aciertos y detectaría cero fallas. Será necesario evaluar recuperación de fallas, precisión y falsas alarmas.

UNIDAD II / ACTIVIDAD DE EVALUACIÓN 1

9. Relación entre velocidad y torque



Se observa una relación inversa: cuando aumenta la velocidad, el torque tiende a disminuir. Es compatible con la forma en que se generó el conjunto a partir de potencia.

Las clases con y sin falla se superponen. Por eso, velocidad y torque por sí solos no separan todos los estados. La asociación visual no prueba causalidad ni constituye una evaluación de un modelo.

Las cuatro visualizaciones del notebook contienen título y ejes: diagramas de caja, histograma, barras y dispersión. Todas se construyen con el mismo archivo original.

UNIDAD II / ACTIVIDAD DE EVALUACIÓN 1

10. Preparación para análisis posteriores

Regresión

Estimar Torque [Nm] a partir de Type, Air temperature [K], Process temperature [K], Rotational speed [rpm] y Tool wear [min]. Excluir identificadores y etiquetas de falla. Serviría para estimar la fuerza de giro bajo distintas condiciones. Evaluar después con MAE y RMSE frente a una referencia que prediga la media.

Clasificación

Predecir Machine failure: 0 sin falla y 1 con falla, usando Type y las cinco mediciones. Excluir TWF, HDF, PWF, OSF y RNF: son resultados de falla y darían pistas indebidas al modelo. Con 3.39% de fallas, la exactitud por sí sola no basta; revisar precisión, recuperación de fallas, F1 y área bajo la curva precisión-recuperación.

Agrupamiento

Usar las cinco mediciones numéricas para identificar perfiles de temperatura, velocidad, torque y desgaste. Ajustar escalas antes de agrupar; comparar después la proporción de fallas y Type por grupo sin utilizarlos para formar grupos. Un grupo no representa automáticamente una máquina averiada.

La codificación de Type y el ajuste de escalas se aprenderán solo con entrenamiento, después de separar datos. La evaluación deberá considerar el orden de generación y el posible parecido entre filas cercanas. Sin marcas de tiempo ni identificación de máquina no puede asegurarse una validación temporal real.

Estas son propuestas para etapas futuras. En esta actividad no se entrenaron modelos ni se realizó limpieza o transformación del archivo original.

UNIDAD II / ACTIVIDAD DE EVALUACIÓN 1

11. Conclusión del diagnóstico

El archivo contiene 10,000 observaciones sintéticas de operación industrial, con seis predictores principales, dos identificadores y seis etiquetas. No hay valores faltantes ni filas completas duplicadas. La integridad básica es buena, pero hay desbalance de clases (339 fallas: 3.39%) y 27 diferencias entre Machine failure y la unión de los modos de falla. Los valores extremos de velocidad y torque se conservarán porque pueden representar operación exigente. Se deben revisar las etiquetas, codificar Type y ajustar escalas solo después de separar entrenamiento y prueba. El dataset permite continuar con el proyecto educativo, sin asumir que demuestra desempeño en maquinaria real.

Pregunta	Conclusión
¿Qué información contiene?	Mediciones de operación, variante y etiquetas de falla sintéticas.
¿Qué nivel de calidad tiene?	Buena integridad básica; requiere revisar coherencia de etiquetas.
¿Qué problemas se identificaron?	Desbalance, extremos y 27 discrepancias de etiquetas.
¿Qué requiere tratamiento?	Type, escalas numéricas, velocidad/torque y revisión de etiquetas.
¿Hay faltantes o duplicados?	Cero faltantes y cero filas completas duplicadas.
¿Hay atípicos?	Sí en velocidad y torque según IQR; conservar y revisar.
¿Qué transformaciones se proponen?	Codificar categorías, ajustar escalas y excluir IDs/etiquetas como entradas según el objetivo.
¿Es adecuado para continuar?	Sí para el proyecto educativo; no demuestra utilidad industrial real.
¿Qué conocimiento se espera?	Perfiles de operación y relaciones con falla, con validación posterior.

UNIDAD II / ACTIVIDAD DE EVALUACIÓN 1

12. Revisión individual y fuentes

Para presentar el trabajo

Abrir el notebook, elegir Python 3 y ejecutar todas las celdas en orden. Mostrar el CSV en data/raw/. Explicar shape, info y isnull().sum(); describir la gráfica de barras y la diferencia entre regresión, clasificación y agrupamiento.

Instalación local: python -m pip install -r requirements-u2.txt. Abrir después Jupyter o el notebook en Visual Studio Code. No se necesita conexión para analizar el CSV ya descargado.

Evidencias

Notebook: notebooks/SalinasLaguna_Diego_U2_AE1_Exploracion.ipynb
Informe: docs/SalinasLaguna_Diego_U2_AE1_Diagnostico.pdf
Original: data/raw/ai4i2020.csv

Fuentes

UCI Machine Learning Repository (2020). AI4I 2020 Predictive Maintenance Dataset. DOI: 10.24432/C5HS5C.
Página oficial del conjunto de datos

Proyecto y planteamiento de la Unidad I:
github.com/diegochat129s-coder/mantenimiento-predictivo-ai4i

Integridad del archivo analizado (SHA-256)

dc6630cd9b1f0f853922fad78a1b6436570d3f1ec863f1dd5c4340ac56bc8a8e